新生研讨课论文

题　目：对提高高校微博影响力方法的探究

组　　号：4

成　　员：董恒、潘多、奴尔江、江巴欧珠

专　　业：计算机科学与技术

指导教师：刘淇

指导学长：何明

2017 年 5 月 21 日

对提高高校微博影响力方法的探究

摘要

本文利用多元回归、词云、K-means 聚类、LDA、Tf-idf、word2vec、PCA、SVC 等方法，借助 pandas、numpy、jieba、matplotlib、re 等库，尝试从不同角度，不同层次对高校微博进行分析，试图找到能够提高微博影响力的方法。

关键词： 情感分析；高校微博；LDA；词云；文本挖掘

目录

第1章　引言：研究背景与目的

微博拥有庞大的用户量，对于高校来说，现在几乎每个高校都拥有自主微博，对于该微博的影响力的提升是提高高校影响力一个很重要的方面。本文试图在获得数据的基础之上探索提高高校微博的办法。

第 2 章　数据获取与转换

2.1 微博数据获取方法概要

新浪微博是一个伪开放平台，微博数据的获取对于研究人员来说是相当有难度的。目前来说微博数据 的获取方法包括：微博 API，第三方软件，爬虫等。

2.2 API 的局限性

新浪微博开放平台提供了二十余类接口，覆盖了微博内容、评论、用户及关系的各种操作，理论上该方法是最直接、方便的方式。但新版的微博开放接口存在一些限制，对于小型研究团队或个人而言不是很方便，突出表现在以下几点[1]：

（1）微博开放接口使用 Oauth2.0 认证授权，如果希望得到另外一个用户的个人信息和微博内容，则必须由该用户授权；

（2）微博开放接口存在访问频次限制，对于测试用户的每个应用，每小时最多只能访问 150 次；

（3）很多研究所需要的数据只能通过高级接口才能访问，需要专门申请和付费。

2.3 第三方软件的不适用

第三方软件尝试了：集搜客[2]，八爪鱼[3]，火车头[4]、爬一爬[5]等等。

其中集搜客是通过 MS 谋数台添加网址、编写主题名、建立整理箱、映射目标抓取内容、样例复制、翻页、多层次网页抓取，再用 DS 打数台爬取数据。然而实际在操作的过程中，对于微博这种有极严格限制的网页，依然存在难以解决的困难。即便是用从专门的规则市场中下载的规则。值得注意的是：集搜客本身是提供专门的微博数据中心的，也就是简单地输入 URl 就可以得到数据，但是这种方式下载数据是收费的。同样的八爪鱼也是收费的。而爬一爬存在不能翻页的问题（这个问题大概只存在于微博这种限制很严的网

站上）。至于火车头，在实际操作过程中，出现了不可名状的错误。另外，还尝试了光年数据获取软件（这个软件确实也解决不了微博问题）以及专门为微博数据爬取写的一款软件 weisperdata（这个软件停止更新了，但是微博本身的限制却越来越严，所以基本不能用）。

商业性质的第三方数据获取方法除了这些软件，还有专门做数据的企业以及淘宝上定制数据或者定制数据爬虫的，价格不菲，可见微博数据的价值以及数据的难以获取。

2.4 爬虫的探究

爬虫是最好的办法，但是对于微博来说，需要解决的问题太多，登录移动端新浪微博、分析网站源码、获得用户的 cookies、获得用户的 ID 等等，除了模拟登录，还需要防止采集次数过快而被封号。鉴于时间有限，在尝试自己写爬虫失败几次后为了不使进度完全停止而放弃了这个方法。不过，这个方法仍然是最好的办法：高度可定制、速度快、可完全满足研究的需要。因而，自写微博爬虫是一个很有价值的课题。

鉴于没有时间自写爬虫，笔者在 GitHub 上找了大概 20 个最近有更新的代码，但是遗憾的是，在解决了一堆问题之后，每个代码都存在知识范围之外的错误（或者问题）。于是放弃这一条路。

2.5 某网站的数据获取方式

在多次失败之后，笔者找到了一个捷径：北京大学微博可视化分析工具[6]，借助这个网站，顺利获取到了可以开展一项研究的数据，只是数据没有完全满足需求，也导致很多想做的研究只能停留在理论层面。

从这个网站上获取到的数据使 json 格式，中文转码方式是 str.decode(‘unicode-escape’)，对数据的结构分析之后分解并以 xls 格式储存。写入用到的库是 xlwt，读出用到的是 xlrd 和 pandas.

目前获取的微博数据（由于后续还有其他不属于微博的数据，特此指明）包括 199 个大学的基本信息（bi_followers 互粉人数、followers 粉丝数、friends 关注数、statuses 微博数、city 城市、province 省份、created_at 账号创建时间、favourites 点赞数、gender 性别、location 位置、name 名字、screen_name 昵称、verified 是否加 V、verified_reason 加 V 原因、verified_type 加 V 类型、uid）、每个大学 100 多个粉丝、关注者的基本信息（同以

上），仍然由于微博的限制，粉丝和关注者的数量只能看到 100 到 200，而实际上粉丝数是以万为单位的。为叙述方便，这个数据集称为 data1.

另一个微博数据集是以 199 个大学为关键词搜索得到的大概 1000 条微博，包括微博的 mid 微博 ID、attitudes 点赞数、comments 评论数、reposts 转发数、created_at 发微博时间、text 博文内容，博主的基本信息（同 data1）。此数据集称为 data2.

还有一个比较小的数据集是 2017 年几个主要高校的博文。称为 data3.

2.6 微博影响力的评判

微博影响力本身是很难界定的，因为这不是一个孤立的体系，也不是几个因子构成的简单函数，微博影响力本身并不完全由微博本身决定，一般而言，最主要的因素是高校本身的绝对实力。如果单纯用某种数量（比如所粉丝的数量）来作为影响力的参照标准，那么高校规模（比如人数，占地面积，校区数量）都会严重干扰微博影响力的评判。

本文并不打算细究这一方面的问题，只是简单地建立在这样一个假设上：粉丝数量，点赞转发评论数量，传播范围（地域与人数）反映了微博的影响力。

第 3 章　基本信息数据的分析

3.1 基本信息数据

基于 data1，我们将上文提到的各类基本信息，统称为基本信息数据。这类数据最明显的是均由数字组成，因此可以直接用模型。

3.2 粉丝数

3.2.1 粉丝数与高校排名关系

在研究开始之初，我们认为高校微博的受欢迎程度与高校的排名有线性关系，于是在将 data1 的 xls 数据再进行一次处理（将各高校微博的粉丝和关注基本信息取平均等等）之后，运用一个网站（魔镜[7]），进行简单的数据可视化，得到的结果如下：

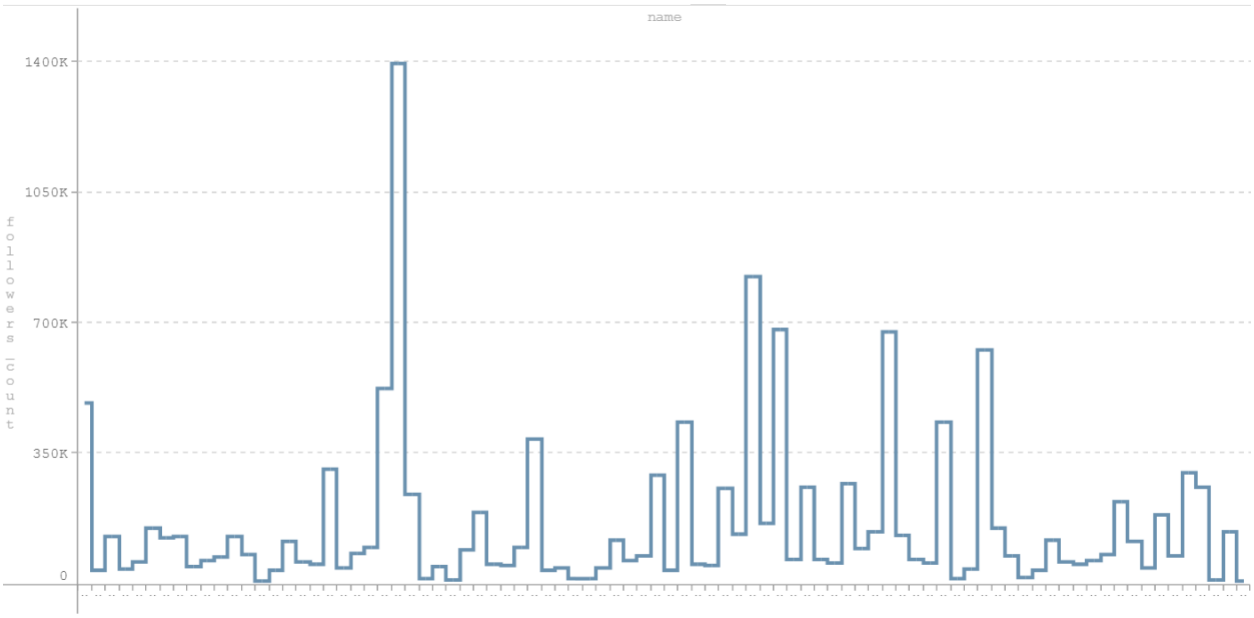

Graph-1 高校排名与粉丝数量关系图

很显然没有线性关系，这个结果也说明高校微博的影响力不仅仅由高校的实力决定，更进一步也说明，这项针对提高微博影响力的探究是有价值的。

3.2.2 标签云

为了更加明确地知道哪个大学微博是影响力比较大的，做了一个标签云：

Graph-2 微博粉丝数量的标签云

注意到占据头条的不是通常认为的著名高校。

3.2.3 粉丝数量的不均匀分布

粉丝数量在高校的分布是很不均匀的，为了说明这一点，做一个散点图:

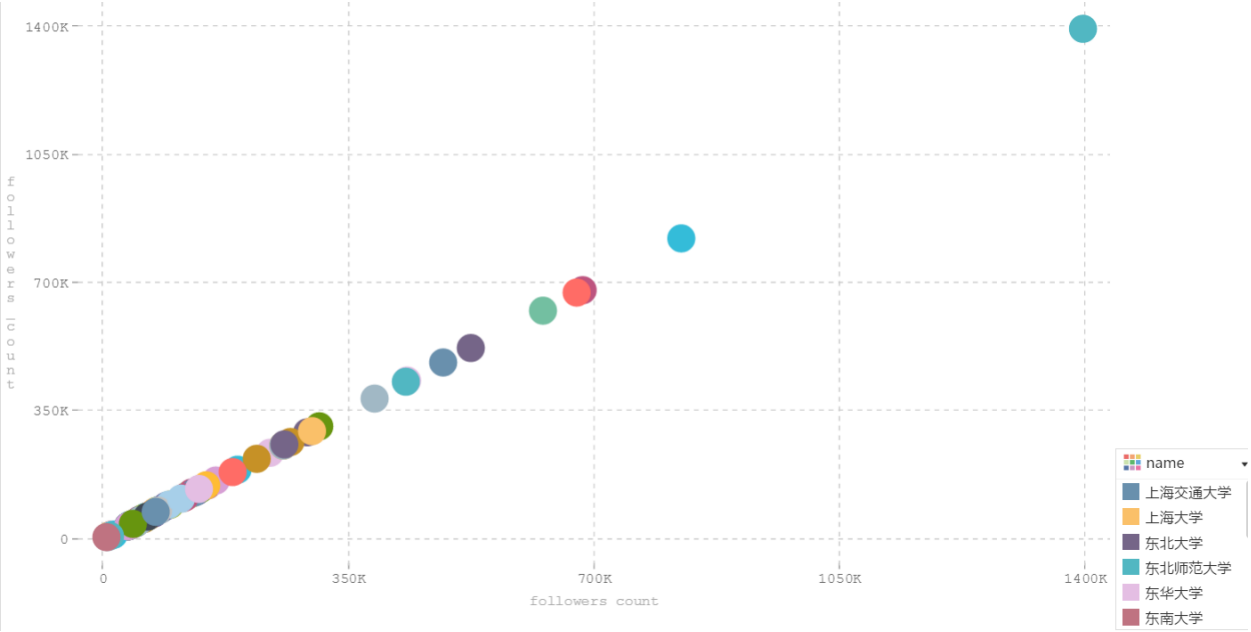

Graph-3 微博粉丝数量散点图

注意到粉丝数量普遍小于 350,000，在 350,000 与 700,000 之间分散很开，而在 1400,000 处有一个相当高的，这意味着粉丝数量有很大的提升空间，并且针对不同层次的高校有不同级别的数量提升空间。

3.3 全部数据的聚类

为了更进一步分析基本数据与高校的关系，笔者根据情况做了 7 个聚类，用到的库为 sklearn.cluster.KMeans。

KMeans 简介：聚类属于无监督学习,K-means 算法是将样本聚类成 k 个簇（cluster），具体算法描述如下[8]:

1、 随机选取k个聚类质心点（cluster centroids）为$\mu_1, \mu_2, \ldots, \mu_k \in \mathbb{R}^n$。

2、 重复下面过程直到收敛 {

对于每一个样例i，计算其应该属于的类

$$c^{(i)} := \arg\min_j ||x^{(i)} - \mu_j||^2.$$

对于每一个类j，重新计算该类的质心

$$\mu_j := \frac{\sum_{i=1}^m 1\{c^{(i)} = j\} x^{(i)}}{\sum_{i=1}^m 1\{c^{(i)} = j\}}.$$

}

Graph- Kmeans 算法描述

取 k=20，现在只取其中一个，用到的是所有的数据（data1），包括高校的基本数据、粉丝和关注者的基本数据（取平均），整理之后结果如图:

北京科技大学/东北大学/湖南师范大学/华中农业大学/南京理工大学/上海交通大学/长安大学/中国海洋大学/中南财经政法大学

首都师范大学

北京航空航天大学/华中师范大学/苏州大学/中国科学技术大学

华南师范大学

东华大学/暨南大学/兰州大学/陕西师范大学/西北大学/西北农林科技大学/浙江师范大学/中山大学

安徽大学

东南大学/华北电力大学/华东师范大学/华南理工大学/中国地质大学/中国石油大学

电子科技大学/哈尔滨工业大学/湖南大学/武汉理工大学/西北工业大学/西南交通大学/燕山大学/中南大学/中央财经大学

北京邮电大学/中国农业大学/中国人民大学

北京林业大学/福州大学/合肥工业大学/华南农业大学/南京航空航天大学/天津大学/西安电子科技大学

北京工业大学

南开大学/厦门大学/同济大学/中国政法大学/中央民族大学

华东理工大学/华中科技大学/南昌大学/山东大学/上海大学/四川大学/西安交通大学/西南财经大学

北京大学/复旦大学

北京师范大学/武汉大学/浙江大学/重庆大学

吉林大学

清华大学

北京交通大学/大连理工大学/对外贸易大学/南京农业大学/云南大学/浙江工业大学/郑州大学/中国矿业大学

哈尔滨工程大学

东北师范大学/广西大学/河海大学/江南大学/南京大学/西南大学

Graph-4 基本数据的聚类

每一行代表一个聚类。聚类是为了得到与某个大学相似的大学（单单指基本信息数据），注意到北京航空航天大学、华中师范大学、苏州大学、中国科学技术大学并列，北京大学、复旦大学并列，清华大学单列，这意味着以上并列大学在基本数据方面是非常相似的，或许也可以从高校风格角度看到相似处。

3.4 微博数

3.4.1 微博数的不均匀分布

另一个需要关注的点是微博数，同样做出散点图，

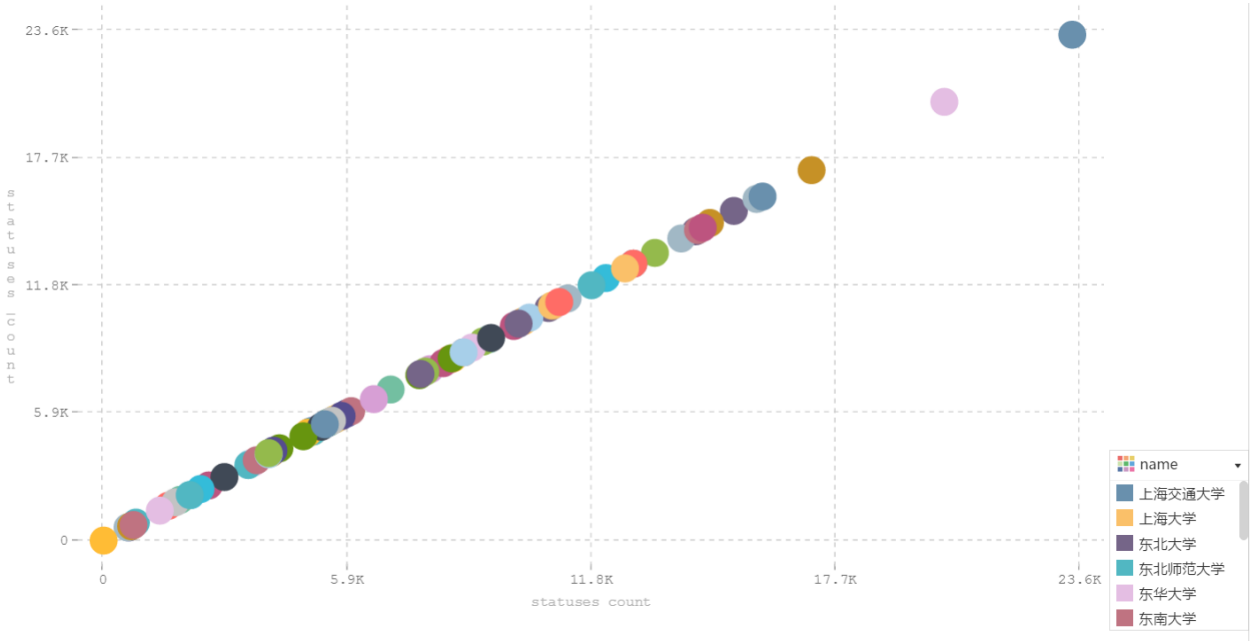

Graph-5 微博数散点图

从 0 到 17,700 相对比较均匀，也有两个大学在更高的层次上。不同数量的微博，说明不同高校对微博的重视程度不同，活跃度不够，我们认为的微博影响力的三个方面：活跃度、传播力、覆盖度，其中活跃度是后面两者的前提。

3.4.2 粉丝数与微博数的关系

那么同时又会想到，微博的活跃度（微博数、与粉丝互动数，本文只考虑微博数）与粉丝数有多大的联系呢？于是做出散点图：

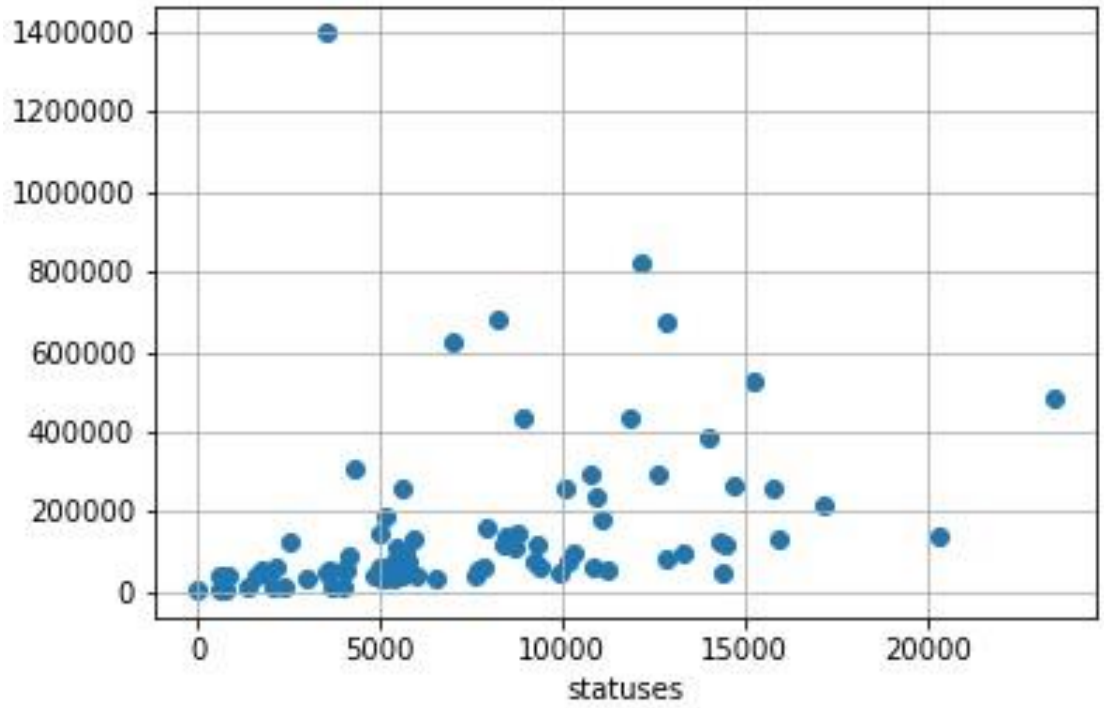

Graph-6 粉丝数-微博数散点图

明显可以看到，粉丝数与微博数有一定程度的线性关系，这也表示提高微博数的活跃度，对提高影响力是有帮助的。

3.5 多元回归

3.5.1 粉丝数与其他基本数据的关系

我们也想知道其他几个基本数据与粉丝数的关系，做出散点图：

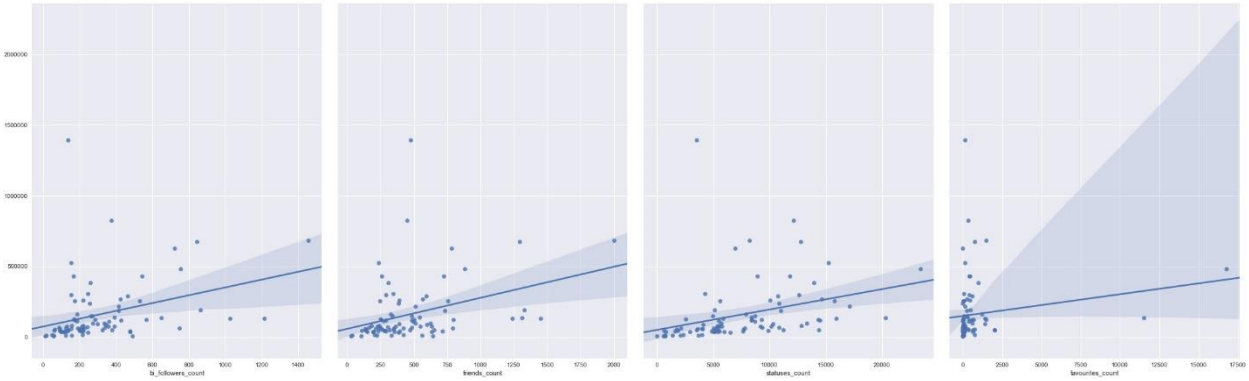

Graph-7 粉丝数与互粉数、关注数、微博数、点赞数散点图

图中直线为最小二乘法拟合直线，两边的区域是 90%的置信区间，发现线性性质不是很明显。

3.5.2 相关系数

为了看到数据，笔者又对基本数据求了相关系数（pandas），输出为 xls 如下：

	bi_followers	followers	friends	statuses	favourites	fr_bi_followers	fr_followers	fr_friends	fr_statuses	fr_favourites	fo_bi_followers	fo_followers	fo_friends	fo_statuses	fo_favourite
bi_followers	1	0.33426	0.958	0.41029	0.290551	-0.434772001	-0.2283162	-0.3975	-0.314341	-0.1294723	-0.249821665	0.01397155	-0.031939	-0.0249922	-0.0809305
followers	0.33425857	1	0.345	0.32336	0.156002	-0.101998712	-0.1128818	-0.10861	-0.076573	0.03732405	-0.206350435	-0.0752811	0.038342	-0.0253108	0.0673607
friends	0.95755276	0.34492	1	0.39145	0.319847	-0.455143362	-0.2375605	-0.44021	-0.289594	-0.1144341	-0.219730498	0.0634644	-0.005837	0.05613568	-0.0991318
statuses	0.41028518	0.32336	0.391	1	0.521378	-0.281785746	-0.2284529	-0.24929	-0.070701	-0.0131094	-0.298776357	-0.0247587	-0.151407	-0.1488509	-0.0813158
favourites	0.29055109	0.156	0.32	0.52138	1	-0.257706795	-0.0852171	-0.27072	-0.113413	-0.0675585	-0.211350051	-0.0414348	-0.097816	-0.0541498	-0.0260510
fr_bi_followers_aver	-0.434772	-0.102	-0.46	-0.2818	-0.25771	1	0.3457435	0.877696	0.4854943	0.18416549	0.108060438	-0.1947707	-0.03681	0.00920256	0.0335279
fr_followers_aver	-0.2283162	-0.11288	-0.24	-0.2285	-0.08522	0.345743527	1	0.304427	0.1048693	0.05327477	0.18091648	-0.0937896	0.020792	0.04434298	0.0049380
fr_friends_aver	-0.397503	-0.10861	-0.44	-0.2493	-0.27072	0.877695865	0.3044271	1	0.4710342	0.16326774	0.123530306	-0.1213794	0.038962	-0.0316954	0.0668744
fr_statuses_aver	-0.3143412	-0.07657	-0.29	-0.0707	-0.11341	0.48549431	0.1048693	0.471034	1	0.51058581	0.271002805	-0.0788207	0.110725	0.19006695	0.0599602
fr_favourites_aver	-0.1294723	0.03732	-0.11	-0.0131	-0.06756	0.184165488	0.0532748	0.163268	0.5105858	1	0.021425966	-0.1648591	-0.027379	-0.1304061	0.0643076
fo_bi_followers_aver	-0.2498217	-0.20635	-0.22	-0.2988	-0.21135	0.108060438	0.1809165	0.12353	0.2710028	0.02142597	1	0.09164894	0.572731	0.41883406	-0.0719201
fo_followers_aver	0.01397155	-0.07528	0.063	-0.0248	-0.04143	-0.194770725	-0.0937896	-0.12138	-0.078821	-0.1648591	0.091648939	1	0.151686	0.28631088	-0.061065
fo_friends_aver	-0.0319388	0.03834	-0.01	-0.1514	-0.09782	-0.036809957	0.0207918	0.038962	0.110725	-0.0273787	0.572731122	0.1516862	1	0.52762311	-0.0187664
fo_statuses_aver	-0.0249922	-0.02531	0.056	-0.1489	-0.05415	0.009202556	0.044343	-0.0317	0.1900669	-0.1304061	0.418834064	0.28631088	0.527623	1	0.1306815
fo_favourites_aver	-0.0809305	0.06736	-0.1	-0.0813	-0.02605	0.033527906	0.0049381	0.066874	0.0599602	0.06430763	-0.071920155	-0.0610655	-0.018766	0.13068154	

Graph-8 基本数据的相关系数表

表中 fr_前缀表示关注者，fo_前缀表示粉丝，_aver 后缀表示平均值，其他同基本数据的介绍，除对角线外的大部分值都接近 0，表示在已得到的数据范围之内，相关性很弱，唯一一个例外是关注者与互粉之间的相关性系数，高达 0.958，实际上原因是高校本身作为大 V，如果某个用户受到大 V 的关注，必然也会关注它，同时，高校之间会相互关注，高校不同部门之间的微博也会相互关注。

3.5.3 多元回归

整体来看，这个表格也说明几个量之间并不是简单的一元线性关系，那么很有可能是多元的线性。于是采用多元回归[9]（sklearn.linear_model.LinearRegression）,得到的结果是：

followers=1002*bi_followers-539*friends+17*statuses-11*favourites

表示每增加一个互粉人数的，粉丝数增加 1002 个，每增加一个关注数，粉丝减少 539 个。于是笔者认为多互粉少关注可以有效增加粉丝数。值得注意的是，之前我们认为增加微博数对增加粉丝数有效，但是此处的系数却只有 17，原因是，为了方便解释其他量的具体对粉丝数的影响，此处的回归没有做归一化，通常来说，微博数占比是比较小的，因而此处的回归对粉丝数影响小也是可以理解的，同时也说明，在一个多因素体系里面，很难找到一个完美的、可以准确解释全部量的模型。

对数据随机分割之后验证，得到的曲线如下：

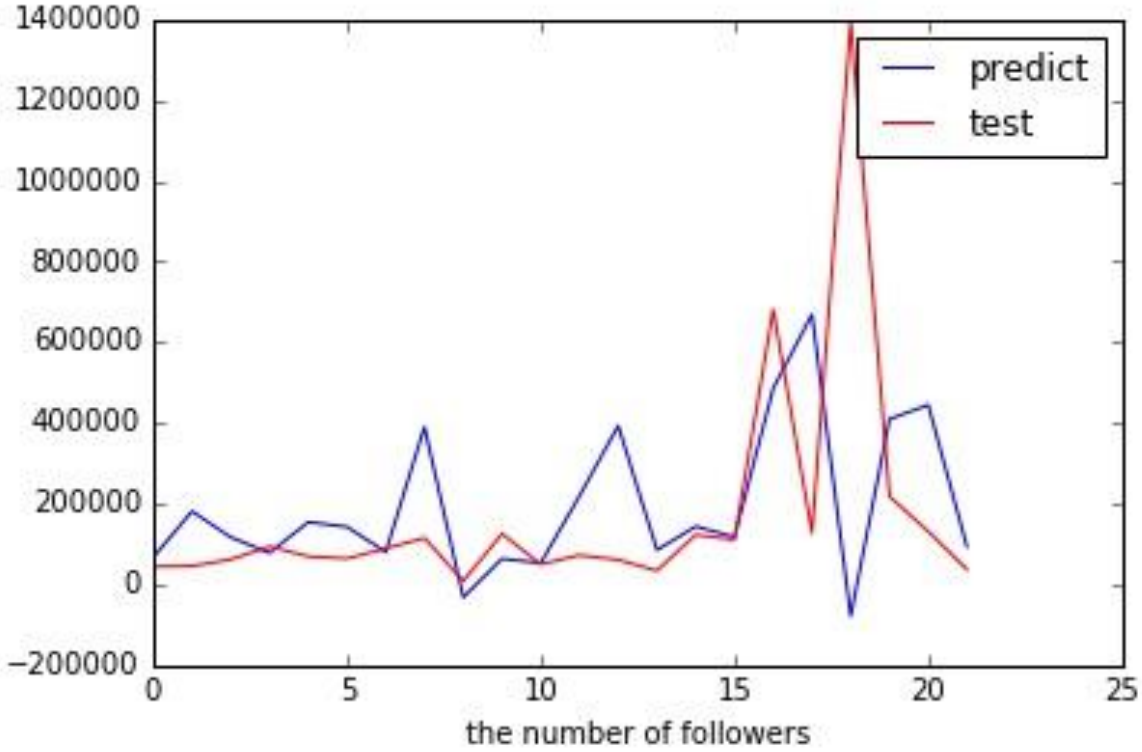

Graph-9 多元回归预测图

发现预测的效果并不是很好，其原因我们认为是数据集不够。于是笔者尝试采用 data2 的非高校用户的数据作为训练集，以 data1 的高校数据作为测试集，预测的结果如下：

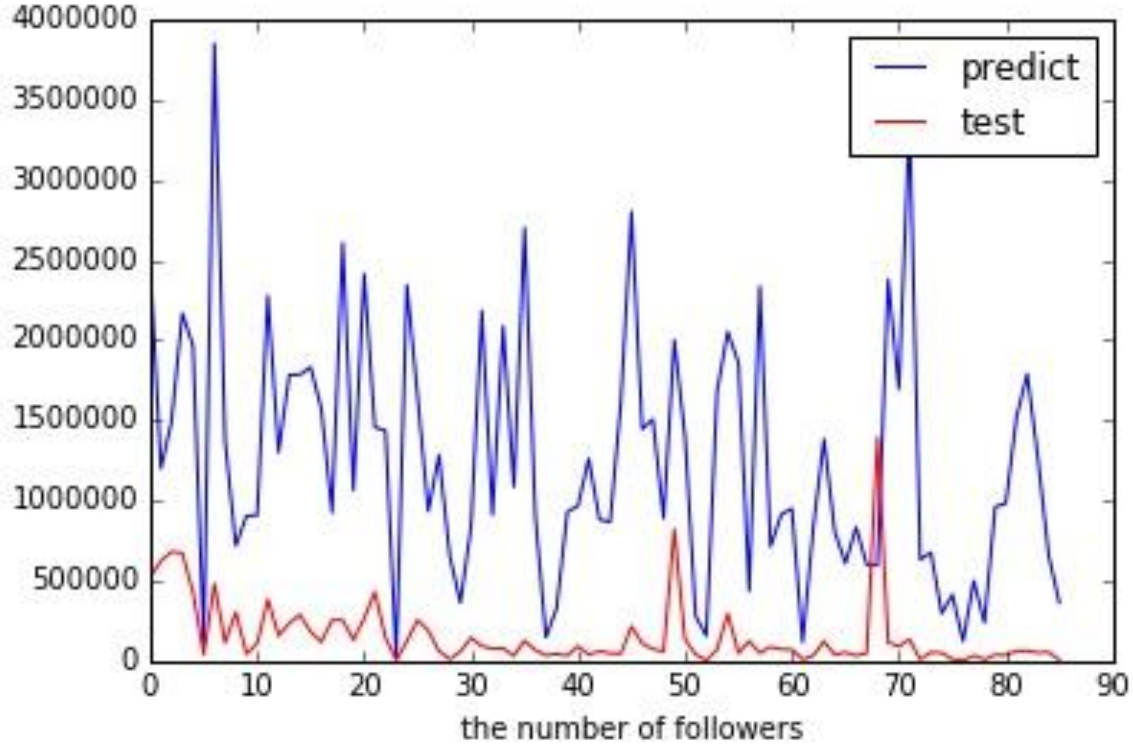

Graph-10 多元回归预测图（2）

却发现预测的效果更加不合理，其原因是，不同用户的数据不具有可比性，具体来说，在微博的研究中，加 V 与不加 V 的用户的数据是有很大的不同的，不可以视为同一类型的量。虽两次的多元回归的预测模型并没有完全达到目的，但是我们仍然相信在数据量有效而且充足的情况下，多元回归模型对粉丝的数量是有预测效果的[19]。

以上基于基本数据的研究告一段落。总结来说，增加微博数，多互粉少关注。对于研究模型，我们认为难以找到唯一完美的，需要对多种模型尝试，同时，在对实际问题的研究中，有效数据量可以放在研究是否有效的第一位。

3.6 本章小结

本章通过各类数据的不同角度的分析，试图找到一个统一的模型来判断什么是主要因素，什么是次要因素，在探究的过程中，由于本身问题的多因素干扰，以及有效数据量的不充足，得出的结论并不是很令人满意，但是基本上还是可以做出一下结论：高校粉丝数量与高校排名没有直接的联系，这也保证了本研究是有效的，也就是说在现有高校实力的情况下，提升微博的影响力还是有效的。之后我们为了直观粉丝数与高校的联系，做了标

签云，更进一步说明粉丝数最多的恰恰不是普遍认为的名校。然后我们做了散点图，看到了粉丝数量的巨大不均匀分布，这也意味着提升的空间是相当巨大的。对于全部的基本数据，我们尝试了使用聚类，希望能用这类数据将某些高校联系在一起，并且发现某些值得借鉴的特征，但是限于对高校的风格了解不够，未能完全解释聚类的结果。

完成了以上内容之后，我们同样对微博数做了散点图，发现不同的大学对微博的重视程度不够，至少在活跃度方面做得不够好，而活跃度被认为是覆盖度和影响力的基本。

之后我们对其他的数据做散点图，试图找出它们与粉丝数的关系，进一步地比较了相关性系数，结果是某两个数据之间的相关性确实不高，这启发了我们使用多元回归。我们尝试了不同数据的多元回归，再已有的数据上，做出了多互粉少关注的结论。

到此，对于基本数据的研究告一段落。后文将主要针对文本分析。

第 4 章　主题提取

4.1 目的概述

前面我们尝试找到具体的可以量化的因素决定或者大范围地影响粉丝数，探究的结果是，很难找到这种因素，或者说，从不同的角度，用不同的模型得到结论不同。那么我们可以换个思路：去模仿某些高校微博的样式，比如清北复旦上交……，以及找到某个高校本身的需要着重描写的主题。

4.2 LDA 主题模型

4.2.1 LDA 对所有微博生成主题[10][11]

主要用到的方法是：分词，去停用词，为词编号，文档用词频的向量表示，TF-IDF 变换，再是 LDA 模型训练。

开始这个模型之初，笔者认为，基于 data2 能够将所有的微博分成几个主题，然后进行了尝试，这里列举 topic=20 和 topic=100 的两个结果：

```
(17, u'0.000*"航空航天" + 0.000*"药大" + 0.000*"拉萨" + 0.000*"藏语" + 0.000*"金珉锡生" + 0.000*"八十" +
0.000*"藏族" + 0.000*"南航" + 0.000*"巴德" + 0.000*"青大"')
(3, u'0.000*"淮南" + 0.000*"天香" + 0.000*"商山" + 0.000*"校微" + 0.000*"北邮" + 0.000*"乳业" + 0.000*"山科"
+ 0.000*"华电" + 0.000*"保定" + 0.000*"安理"')
(5, u'0.000*"女足" + 0.000*"安农" + 0.000*"三下乡" + 0.000*"富彦斌" + 0.000*"青基会" + 0.000*"地产" +
0.000*"农经" + 0.000*"马鞍山" + 0.000*"第十二届" + 0.000*"激扬"')
(15, u'0.000*"会内培" + 0.000*"福师" + 0.000*"现代科技" + 0.000*"江财" + 0.000*"江财麦庐" + 0.000*"石家庄" +
0.000*"汇华" + 0.000*"南京" + 0.000*"撩衣" + 0.000*"校运会"')
(12, u'0.000*"工大" + 0.000*"孔垂楠" + 0.000*"直径" + 0.000*"东财" + 0.000*"阜新" + 0.000*"石之光" +
0.000*"葫芦岛" + 0.000*"南京农业" + 0.000*"石牌" + 0.000*"第十一届"')
(7, u'0.000*"科艺" + 0.000*"英华" + 0.000*"工场" + 0.000*"泰安" + 0.000*"白举" + 0.000*"富彦斌" + 0.000*"胃
健" + 0.000*"青岛" + 0.000*"無止橋" + 0.000*"摔死"')
(19, u'0.000*"西财" + 0.000*"苏德矿" + 0.000*"天府" + 0.000*"呼和浩特" + 0.000*"夏露" + 0.000*"老伴儿" +
0.000*"小玉" + 0.000*"政权" + 0.000*"宁大" + 0.000*"张奚若"')
(4, u'0.000*"长理" + 0.000*"南林" + 0.000*"玻璃杯" + 0.000*"华清" + 0.000*"挑份" + 0.000*"带饭" + 0.000*"呈
贡" + 0.000*"新疆" + 0.000*"南瓜" + 0.000*"川大"')
(9, u'0.000*"衣冬" + 0.000*"银川" + 0.000*"井穴" + 0.000*"团支书" + 0.000*"光子" + 0.000*"华理" + 0.000*"威
海" + 0.000*"大庆" + 0.000*"体育运动" + 0.000*"风雷"')
(10, u'0.000*"威海" + 0.000*"三翼" + 0.000*"马鞍山" + 0.000*"造假" + 0.000*"二手市场" + 0.000*"丢人" +
0.000*"温州" + 0.000*"环资" + 0.000*"华政" + 0.000*"湘大"')
```

Graph-11 topic=20 时所有微博的 lda 模型

```
(68, u'0.000*"压岁钱" + 0.000*"质量技术监督局" + 0.000*"公三" + 0.000*"顾得上" + 0.000*"形象设计" + 0.000*"问
政于民" + 0.000*"瑞峰" + 0.000*"宿昔" + 0.000*"季梓琨" + 0.000*"委培"')
(26, u'0.001*"浙师" + 0.000*"浙师大" + 0.000*"金华" + 0.000*"我原" + 0.000*"肥肉" + 0.000*"杨沁" + 0.000*"浙
师微" + 0.000*"油菜花" + 0.000*"美不美" + 0.000*"因吹斯"')
(56, u'0.000*"归零" + 0.000*"焦虑" + 0.000*"吴晓求" + 0.000*"靳诺" + 0.000*"金砖" + 0.000*"尼颖" + 0.000*"重
阳" + 0.000*"民法" + 0.000*"总则" + 0.000*"咖有"')
(47, u'0.000*"裤子" + 0.000*"二鸟" + 0.000*"一裤" + 0.000*"最懒" + 0.000*"两周" + 0.000*"无印" + 0.000*"洋
毒" + 0.000*"转基因" + 0.000*"最懒生" + 0.000*"转增"')
(63, u'0.000*"黑大" + 0.000*"萧红" + 0.000*"马龙" + 0.000*"室内环境" + 0.000*"甲醛" + 0.000*"萧军" +
0.000*"画传" + 0.000*"哈尔滨" + 0.000*"绿柳" + 0.000*"龙队"')
(86, u'0.000*"东财" + 0.000*"资土" + 0.000*"东大" + 0.000*"函授" + 0.000*"二手市场" + 0.000*"行政法" +
0.000*"西政" + 0.000*"扬大" + 0.000*"价值观" + 0.000*"冶金"')
(3, u'0.000*"天香" + 0.000*"乳业" + 0.000*"福林" + 0.000*"杜凤莲" + 0.000*"工大" + 0.000*"现代科技" +
0.000*"舞弊者" + 0.000*"杨劼" + 0.000*"许魏洲" + 0.000*"阜新"')
(72, u'0.001*"西科" + 0.000*"工场" + 0.000*"光子" + 0.000*"富彦斌" + 0.000*"纠缠" + 0.000*"量子" + 0.000*"科
学技术" + 0.000*"创客" + 0.000*"测绘" + 0.000*"良好开端"')
(32, u'0.000*"陈玲" + 0.000*"杏林" + 0.000*"交大" + 0.000*"工大" + 0.000*"西南交大" + 0.000*"兰州" +
0.000*"天津" + 0.000*"马鞍山" + 0.000*"中医" + 0.000*"患癌"')
(41, u'0.001*"科艺" + 0.000*"浙工大" + 0.000*"秦皇岛" + 0.000*"之江" + 0.000*"里仁" + 0.000*"经管" +
0.000*"嘉庚" + 0.000*"厦大" + 0.000*"科考船" + 0.000*"燕大"')
```

Graph-12 topic=100 时所有微博的 lda 模型

综合来看，虽然生成了模型，但是仔细看每个主题，却发现并不是联系很紧密，也就是意味着主题的生成不成功。这里的主题生成方法是：将某个高校所有 data2 的微博视为一个文档，但是实际上，这里看做的一个文档，不成立，因为高校的关键词微博包含各种各的内容，不能构成一个主题，这也是短文本在文本分析方面的一个弊端。

4.2.2 LDA 对某个大学生成主题

基于上述原因，笔者对某个大学生成主题模型，此处用到的数据是 data3.也就是高校微博。为了对比看出主题的不同之处，这里直接列出 4 个大学的主题：

```
(0, u'0.004*"映像" + 0.003*"艺术" + 0.003*"开学" + 0.003*"链接" + 0.003*"网页" + 0.003*"合作" + 0.002*"新闻"
+ 0.002*"献血" + 0.002*"大会" + 0.002*"一二"')
(1, u'0.004*"课程" + 0.003*"学者" + 0.003*"慕课" + 0.002*"全球" + 0.002*"人类" + 0.002*"扎实" + 0.002*"影响"
+ 0.002*"三院" + 0.002*"遗址" + 0.002*"更好"')
(2, u'0.004*"映像" + 0.003*"实践" + 0.003*"链接" + 0.003*"网页" + 0.003*"情怀" + 0.003*"研究生" + 0.003*"郑
德焰" + 0.003*"核电" + 0.003*"研究" + 0.002*"再见"')
(3, u'0.003*"水清木" + 0.003*"春分" + 0.003*"买书" + 0.003*"潘光旦" + 0.002*"多功能" + 0.002*"七十二变" +
0.002*"教学楼" + 0.002*"液滴" + 0.002*"映像" + 0.002*"材料"')
(4, u'0.003*"调控" + 0.003*"绿色" + 0.003*"植树节" + 0.002*"题为" + 0.002*"全文" + 0.002*"发表" + 0.002*"厉
害" + 0.002*"名人名言" + 0.002*"分子" + 0.002*"结构"')
(5, u'0.004*"映像" + 0.003*"倪维斗" + 0.003*"集体" + 0.003*"网页" + 0.003*"链接" + 0.003*"会士" + 0.003*"小
康" + 0.002*"第三届" + 0.002*"力量" + 0.002*"一二"')
(6, u'0.003*"时代" + 0.003*"初心" + 0.003*"映像" + 0.003*"院系" + 0.003*"十国集团" + 0.002*"继续前进" +
0.002*"挑战" + 0.002*"故居" + 0.002*"牵挂" + 0.002*"视频"')
```

Graph-13 清华微博 LDA

```
(0, u'0.004*"分享" + 0.003*"时间" + 0.002*"互动" + 0.002*"演讲" + 0.002*"考研" + 0.002*"视频" + 0.002*"自由"
+ 0.002*"抱怨" + 0.002*"掌控" + 0.002*"情况"')
(1, u'0.002*"互动" + 0.002*"北京" + 0.002*"过个" + 0.002*"酒量" + 0.002*"早安" + 0.001*"腊梅" + 0.001*"考研"
+ 0.001*"下雪" + 0.001*"微风" + 0.001*"欲言又止"')
(2, u'0.006*"每周" + 0.006*"点歌" + 0.004*"互动" + 0.003*"视频" + 0.003*"分享" + 0.002*"酒量" + 0.002*"过个"
+ 0.002*"礼节" + 0.002*"春节" + 0.002*"礼物"')
(3, u'0.002*"晚安" + 0.002*"早安" + 0.002*"点歌" + 0.002*"每周" + 0.002*"互动" + 0.002*"分享" + 0.002*"成绩"
+ 0.002*"视频" + 0.002*"乃是" + 0.002*"今夏"')
(4, u'0.003*"努力" + 0.002*"视频" + 0.002*"分享" + 0.002*"时间" + 0.001*"早安" + 0.001*"有人" + 0.001*"国家"
+ 0.001*"演讲" + 0.001*"成绩" + 0.001*"关注"')
(5, u'0.003*"师大" + 0.003*"早安" + 0.003*"北京" + 0.002*"生命" + 0.002*"气象" + 0.002*"光影" + 0.002*"微风"
+ 0.002*"来来来" + 0.002*"小南" + 0.002*"再战"')
(6, u'0.005*"师大" + 0.003*"晚安" + 0.002*"明天" + 0.002*"南风" + 0.002*"白天" + 0.002*"气温" + 0.002*"气象"
+ 0.002*"北转" + 0.002*"春天" + 0.002*"北师大"')
```

Graph-14 北师大微博 LDA

```
(0, u'0.004*"南开" + 0.003*"晚安" + 0.002*"意义" + 0.002*"早安" + 0.002*"南小开" + 0.002*"事情" + 0.002*"加
油" + 0.002*"警惕" + 0.002*"前途" + 0.002*"走走"')
(1, u'0.005*"随影" + 0.004*"南开" + 0.003*"转需" + 0.003*"消磨" + 0.003*"一种" + 0.003*"毕淑敏" + 0.003*"杂
耍" + 0.003*"朴素" + 0.003*"众人" + 0.003*"千金"')
(2, u'0.012*"随影" + 0.007*"南开" + 0.004*"转需" + 0.004*"小开" + 0.003*"南小开" + 0.003*"晚安" + 0.002*"评
论" + 0.002*"早安" + 0.002*"打货" + 0.002*"第一名"')
(3, u'0.004*"南开" + 0.004*"加油" + 0.003*"成绩" + 0.003*"晚安" + 0.003*"快乐" + 0.003*"南小开" + 0.003*"遇
见" + 0.003*"早安" + 0.002*"图片" + 0.002*"赫胥黎"')
(4, u'0.004*"受欢迎" + 0.004*"南小开" + 0.003*"演讲" + 0.003*"南开" + 0.003*"睡不着" + 0.003*"迄今为止" +
0.003*"早安" + 0.003*"图书馆" + 0.003*"聚焦" + 0.003*"开花"')
(5, u'0.005*"南小开" + 0.005*"转发" + 0.004*"寒假" + 0.004*"一张" + 0.004*"搞定" + 0.004*"导图" + 0.004*"转
给" + 0.004*"手册" + 0.004*"送给" + 0.004*"思维"')
(6, u'0.008*"南小开" + 0.005*"最想" + 0.004*"地方" + 0.004*"寒假" + 0.003*"津南" + 0.003*"南开" + 0.003*"早
安" + 0.003*"招聘" + 0.003*"诗词" + 0.003*"开学"')
```

Graph-15 南开微博 LDA

```
(0, u'0.014*"再见" + 0.005*"晚安" + 0.005*"小伙伴" + 0.003*"早安" + 0.003*"哈工大" + 0.003*"图片" +
0.002*"分享" + 0.002*"人生" + 0.002*"奋斗" + 0.002*"明天"')
(1, u'0.009*"丁香" + 0.008*"校园" + 0.008*"开满" + 0.008*"丁香花" + 0.007*"晚安" + 0.007*"微博" + 0.005*"转
发" + 0.005*"哈工大" + 0.004*"早安" + 0.004*"网络"')
(2, u'0.006*"早安" + 0.003*"温度" + 0.003*"哈工大" + 0.003*"环境" + 0.002*"志强" + 0.002*"图片" + 0.002*"丁
香花" + 0.002*"丁香" + 0.002*"科学" + 0.002*"晚安"')
(3, u'0.008*"早安" + 0.004*"温度" + 0.003*"哈工大" + 0.003*"图片" + 0.003*"一周" + 0.003*"青春" + 0.003*"吴
朋" + 0.002*"志强" + 0.002*"晚安" + 0.002*"最美"')
(4, u'0.008*"再见" + 0.007*"早安" + 0.006*"校园" + 0.005*"丁香" + 0.005*"开满" + 0.004*"温度" + 0.004*"图片"
+ 0.004*"哈工大" + 0.003*"晚安" + 0.003*"转发"')
(5, u'0.020*"开满" + 0.019*"丁香" + 0.017*"校园" + 0.005*"早安" + 0.005*"晚安" + 0.004*"哈工大" + 0.003*"网
络" + 0.003*"温度" + 0.003*"图片" + 0.003*"再见"')
(6, u'0.006*"丁香" + 0.006*"开满" + 0.006*"晚安" + 0.006*"校园" + 0.004*"早安" + 0.004*"哈工大" + 0.003*"网
络" + 0.003*"图片" + 0.002*"经历" + 0.002*"温度"')
```

Graph-16 哈工大微博 LDA

对比可以看出，偏理工的大学，像清华，主要的主题均偏向于科技简报，而注重人情的大学，总会有一个单独的主题是：早安晚安内容。所以笔者认为，增加微博的特制内容与原创内容，可以有效增加粉丝数目。此处的特制内容指的是像早安晚安类似的，除此之外，还有专门针对粉丝的推荐内容、建议等等，总之，不可以把微博当成高校的新闻简报粘贴处。

4.3 其他主题提取方法

基于上述想法，我们认为，仍然有必要用其他的方法提取主题，或者更加简单的，提取关键词。那么提取关键词的方法将能够应用于微博管理。

4.3.1 简单关键词的提取

关键词的提取方法：1000 条微博的转发、评论、点赞数量归一化（归一化指的是使数据的方差为 1，平均数为 0），再相加，大于零的微博视为有效，再根据词频确定关键词。

为了方便叙述，我们以北大和中科大为例，这里的数据是 2017 年 3 月份的，所以与现在的有些出入，更新的内容将在本文最后的部分统一给出。

```
电影 -> 6
中心 -> 6
雄安 -> 18
老师 -> 7
北大 -> 18
专家 -> 6
课题组 -> 8
陈兴良 -> 6
辱母 -> 5
主讲 -> 5
刑事责任 -> 5
应负 -> 5
发展 -> 8
正当防卫 -> 5
清华 -> 9
杀人案 -> 5
嫌疑人 -> 5
简称 -> 6
保护 -> 6
迁至 -> 6
生命科学 -> 6
山东 -> 5
保送 -> 5
改名 -> 6
天津 -> 8
刷新 -> 9
位列 -> 8
2017 -> 13
潘建伟 -> 7
卫星 -> 8
光子 -> 26
世界纪录 -> 10
发布 -> 10
院士 -> 7
清华 -> 7
墨子 -> 7
纠缠 -> 23
上海 -> 7
量子 -> 14
研究 -> 11
科大 -> 8
排名 -> 19
科学技术 -> 34
hp -> 29
制备 -> 7
科学家 -> 8
首次 -> 13
国际 -> 10
```

Graph-17 北大、中科大关键词

在数据搜集的时间里，当谈到北大的时候，人们普遍谈论的是雄安，辱母杀人案，而中科大是潘建伟，因而，笔者认为，各自的微博，可以适当增加这方面的内容，并且尽量显得原创和独到。

4.3.2 词云

为了更加方便地显示出关键词，使这种方法便于实际应用，笔者进行可视化，即生成词云。

词云的生成方法：jieba 分词后筛除无效词语，用到了 wordcloud.WordCloud.需要注意的是生成中文词云时，要改一下字体，否则无法正常生成。关键代码为：

```
word_cloud=WordCloud(font_path=r"C:\Windows\Fonts\msyh.ttc",
                     background_color='white').generate(cut_text)
word_cloud.to_file(filePath)
```

Graph-18 北大、中科大词云

与前面的关键词生成结果类似，只是更加便于实际应用。

主题的提取我们分成了某个大学的微博的主题提取，某个大学微博关键词的关键词提取，前者是为了横向运用与其他的高校，后者是针对某个大学，为该大学提供关键词的提示。对于高校的关键词微博（data2），除了提供主题和关键词，笔者另外想到的是提供情感监测。

4.4 本章小结

本章通过了三种方法找主题或者关键词，对于 LDA，整体上可以使用，但是目前我们没有对 topic 数目优化，导致生成的主题不够紧密，以及主题之间有交叉。后面我们又用关键词和词云提取中心词。主题提取的目的，一是为了找到某个大学微博的主题，以便借鉴，二是为后文的情感分析服务。

第 5 章 情感分析

5.1 情感分析的目的

情感分析最开始的目的是用情感来作为分类依据，得到得分最高的高校，然后分析出特征。实际探究过程中，却发现情感作为监测更加合适。

5.2 基于词典的情感分析

5.2.1 基于词典的情感分析方法[12]

基于词典的情感分析方法：通过情感打分的方式进行文本情感极性判断，score>0 判断为正向，score<0 判断为负向。

情感词典及其对应分数，来源于 BonSonNLP 数据下载的情感词典，来源于社交文本，所以词典适用于处理社交媒体的情感分析。

```
1  晶尼玛 -6.70400012637
2  抗民 -6.49756445867
3  fuck... -6.32963390433
4  RNM -6.21861284426
5  wcnmlgb -5.96710044003
6  2.5: -5.90459648251
7  Fxxk -5.87247473641
8  MLP -5.87247473641
9  吃哑巴亏 -5.77120419579
10 IAQI -5.77107837123
11 MLGBD -5.69408191501
12 NNND -5.66228462641
13 MLGB. -5.60457743583
14 成甘 -5.60457743583
15 晶桑 -5.60457743583
16 真无语 -5.60457743583
17 TM -5.60457743583
18 次奥次奥次奥 -5.59258287133
19 cnmd -5.54446545761
20 MBD -5.50280109843
21 NNDX -5.48173951768
22 水轻 -5.48173951768
23 美素丽 -5.48173951768
24 草尼 -5.48173951768
25 凌迟 -5.46005372985
26 尼玛尼玛尼玛 -5.42622557462
27 冠周炎 -5.41616190446
28 加塞儿 -5.41616190446
29 日尼玛 -5.41616190446
30 耩仲 -5.41616190446
31 MD... -5.34746092937
32 shit.... -5.34746092937
33 人清 -5.34746092937
34 风疹块 -5.34746092937
35 TMD -5.34746092937
36 真桑心 -5.30440443402
37 NND... -5.27532412618
38 延机 -5.27532412618
39 毛明天 -5.27532412618
40 逆流 -5.27532412618
41 肺病 -5.23415259142
```

Graph- Boson_NLP_sentiment_score

词典把所有常用词都打上了唯一分数有许多不足之处。其一，不带情感色彩的停用词会影响文本情感打分。其二，由于中文的博大精深，词性的多变成为了影响模型准确度的重要原因。一种情况使同一词在不同的语境下可以是代表完全相反的情感意义，另一种情况是，同一个词可作多种词性，那么情感分数也不应该相同。

否定词词典，否定词的出现将直接将句子情感转向相反的方向，而且通常效用是叠加的，常见的否定词：不、没、无、非、莫、弗、勿、毋、未、否、别、休等等。

程度副词词典：既是通过打分的方式判断文本的情感正负，那么分数绝对值的大小则通常表示情感强弱，从《知网》情感分析用词集（beta 版）下载。情感副词权值[13]如下：

type	权值
超|over	1.5
很|very	1.25
极其|extreme / 最|most	2
较|more	1.2
欠|insufficiently	0.5
稍|-ish	0.8

Graph- 情感副词权重

用到的数据还包括停用词，基本步骤[14]如下：

由于微博属于短文本，因此，我们将一篇微博视为同一个句子。然后对文本进行中文分词处理，将处理后得到的单词依次与预先构建好的情感词表逐个查找，若能找到，则是情感词，并读取情感极性及相应权值，否则不是情感词，则进入下一个候选单词，直至整句话判断结束。由于汉语中存在多重否定现象，即当否定词出现奇数次时，表示否定意思；当否定词出现偶数次时，表示肯定意思，因此将上文提到的否定词，构建成一个否定词词典，权值为-1.另外，当程度词修饰情感词，该情感词的情感倾向程度发生了变化，从而需要用上文提到的程度副词词典（该词典把程度副词划分为 6 个等级，每个程度副词定义了一个权重，被程度副词修饰后的情感词及其权重应做相应调整。因此，此时可以求出意群的情感值：

情感群-情感值=(-1)^情感词*程度副词权重*情感词权重

在实际应用中又发现，当一个句子中同时出现否定词和程度词时，由于否定词和程度词相对位置的不同，会引起情感的不同。因此也需要做出相应的调整。

当然，本算法还有很多值得改进的地方，比如句子是有词语根据一定的语言规则构成的，应该把句子中词语的依存关系纳入到句子情感的计算过程中，可根据句子依存关系，从句子的根节点开始对每个词进行情感倾向计算，根据句子依存关系求出句子的情感倾向和情感值。文档的情感，也应该根据句子的不同重要程度来计算，根据句子对文档的重要程度赋予不同权值，调整其对文档情感的贡献程度。确定句子的重要程度，可以根据句子在文档中的位置，根据句子中所含信息量的大小，句子中所含关键词的多少等等。

具体代码参照《基于情感词典的文本情感极性分析相关代码》[15]

5.2.2 对某个大学的情感得分曲线

同样的，笔者对北大和中科大的微博（data2）得出了情感得分，排序之后得到图如下：

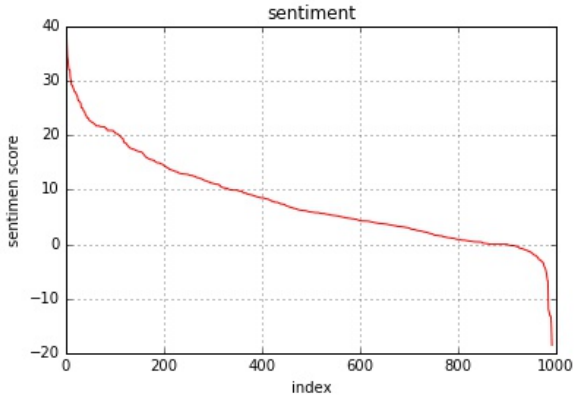

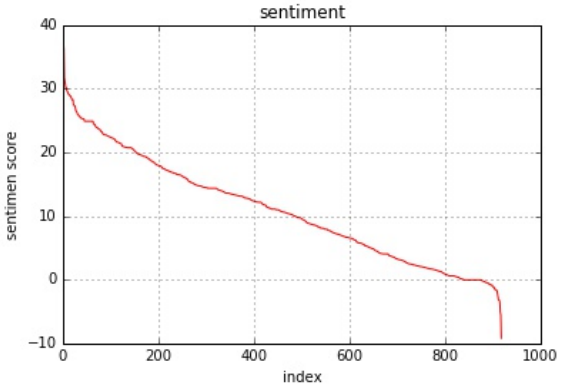

Graph-19 北大、中科大情感得分

需要关注的点是：最高点、最低点、小于 0 部分的陡峭程度。北大的最高点高于中科大，最低点低于中科大，表示群众对北大的情绪范围较大，但基本属于正常。小于 0 部分的陡峭程度则反映了这段时间该博主的是否异常，如果很陡，则说明只有少部分的黑粉，民众的情绪并不是普遍的低或者厌恶，而一旦出现缓慢或者负面积较大的情况，就说明出问题了。后面会举例说明。

另外，其他的监控点需要更进一步的发掘。

应用于某个大学之后，我们想到的是所有大学的情感得分与大学排名是否有关系？如果有关系，有怎样的关系？又该如何利用这种关系？于是笔者打算计算所有大学的情感得分，但是，基于词典的办法已经不再适用，原因在于，这种方法是用 python 写的，运行速度很慢，全部运行完成大概 16 个小时，解决办法有两个，一是用 C++重写代码，二是换用基于机器学习的办法。笔者采用第二种。

5.3 基于机器学习的情感分析[16]

5.3.1 基于机器学习的情感分析方法

同样的，需要准备的数据包括：停用词，正负向预料库。预处理步骤也是分词和去停用词。重点是训练词向量（词向量简单地说是，每个词都位于上下文之中，于是可以建立词汇之间的联系，也就是可以得到词汇本身的特征，这个特征用向量表示）。笔者训练词向量时，用到了搜狗全网数据，化成 csv 文件之后有 1.33GB，使用 gensim.models.word2vec，每个词向量[17]有 400 维，在笔者的电脑上一共训练了 50 分钟。

然后再对正负语料分词，笔者用到的正负语料是酒店评论和书评的正负语料合集各 3800 条。将正负语料分成训练集和测试集，后用上述词向量模型生成模型，再标准化(sklearn.preprocessing.scale)，然后使用 PCA 降维到 100 维(sklearn.decomposition.PCA)，降维的目的是为了减少运算量。最后使用支持向量机(分类)训练(sklearn.svm.SVC)

代码参见[18]

5.3.2 结果

对语料测试之后得到的结果如下：

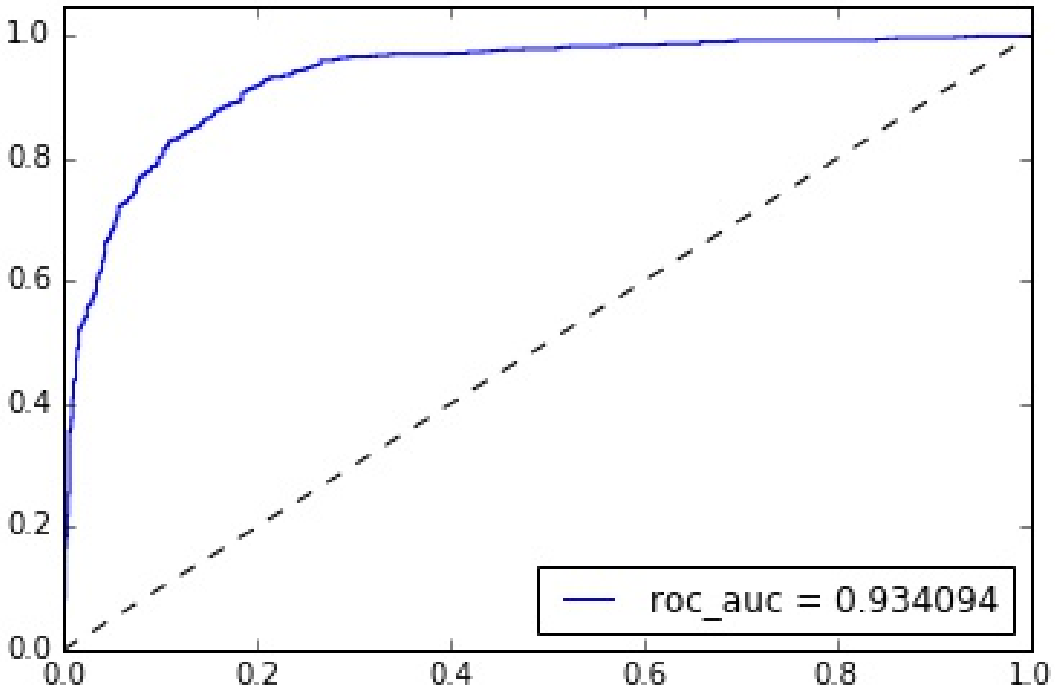

Graph-20 语料预测结果

曲线越靠近左上角代表模型建立的效果越好，从图中可以看出来，测试的效果比较好。于是笔者应用于 199 个大学，按照大学的排名进行排序。得到的图像如下：

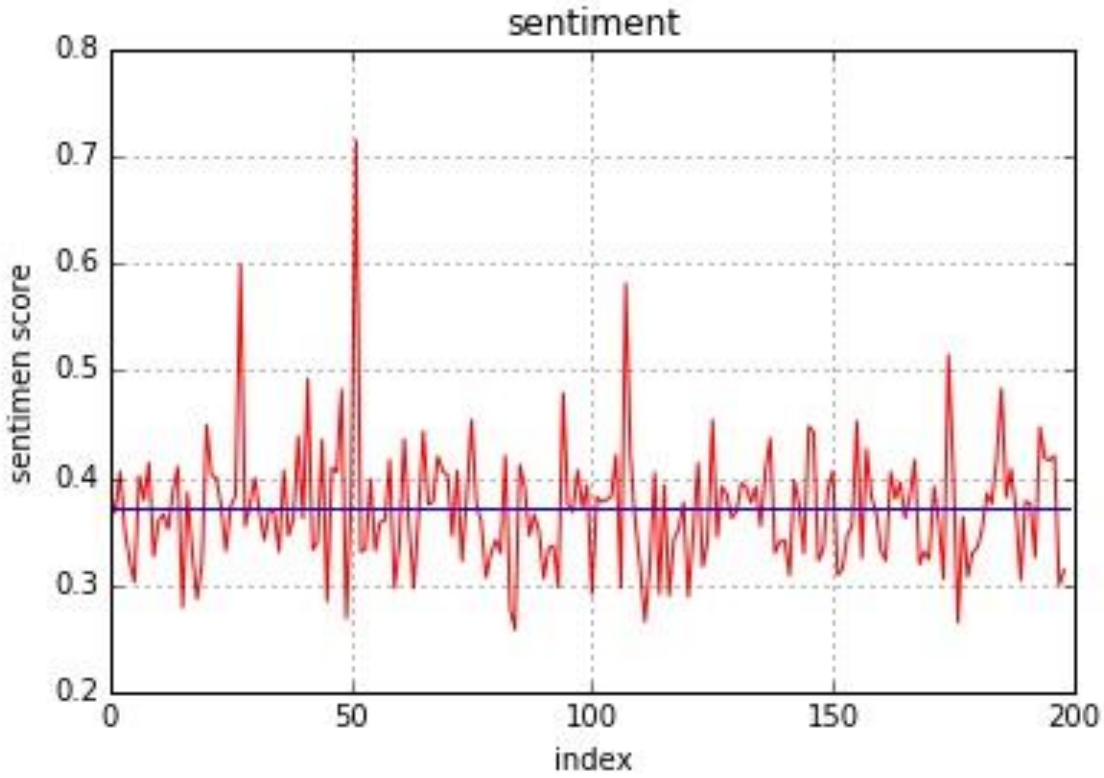

Graph-21 199 个大学情感得分（以大学排名为序）

从图中可以发现，情感的分布与大学的排名没有直接的相关性，其原因很有可能是，情感得分只是一段时间的结果，某个大学的情感得分会随着新的事件的发生而发生改变，是一个波动的过程，那么，对这个波动的过程的监测将作为情感监测的主要任务。在此之前，我们需要一个阈值，当低于这个值，就可以发出警告，为此，我们将得分排序：

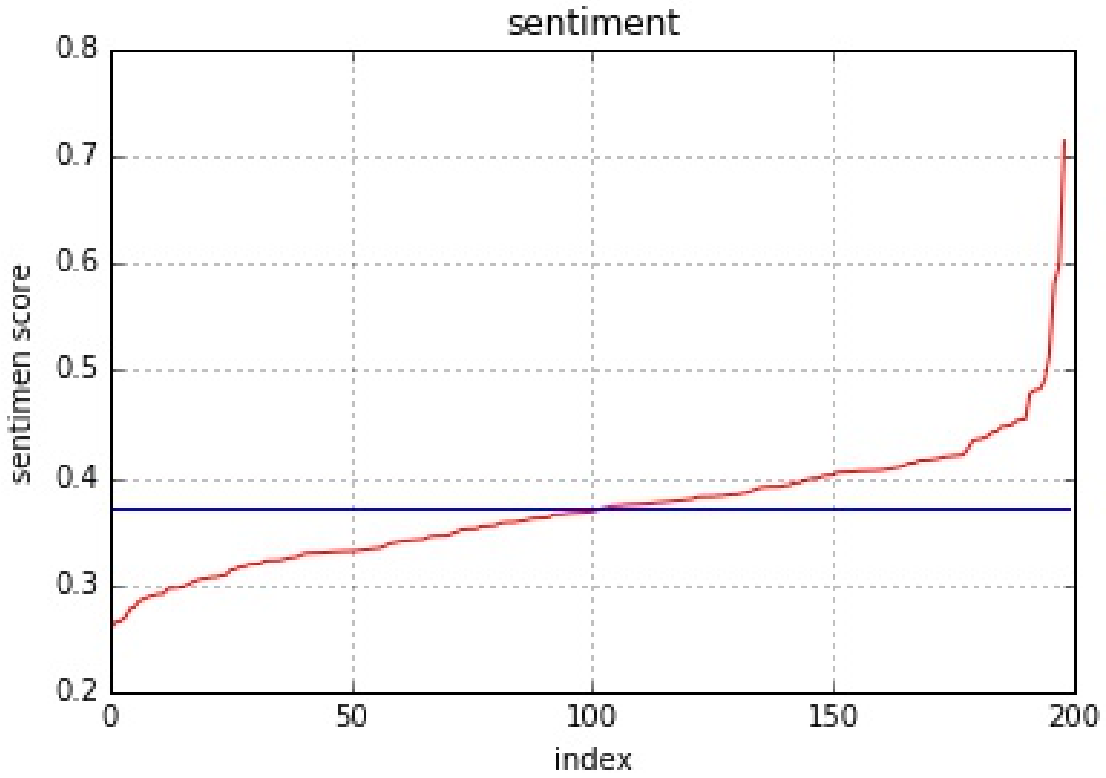

Graph-21 199 个大学情感得分（以得分大小为序）

中间的绿色线为平均分，因此，大概设置这个阈值为平均值 0.37，更加精细的，可以设置不同层次的阈值，比如说 0.32，在低于这个值的时候代表出了很严重的问题。

到这里，我们建立了一个监测的机制，可以是某个高校的相关微博的得分曲线，观察监测点，也可以是总得分，与阈值比较。这种监测机制，再应用一次之前的关键词主题提取，就可以准确判断群众对该高校的状态，了解这个状态，微博可以做准确的调整，对于提高影响力和声誉是很有必要的。

以上对于微博影响力的研究，都停留在一个比较小的方面，没有涉及到微博本身是一个关系网络，实际上，，笔者认为，这个关系网，是微博研究价值非常大的一部分，但是，由于目前无法获取到该类型的数据，所以也没有办法开展这方面的研究，尽管如此，本文还是有一小部分的关于微博传播的部分。

5.4 情感分析应用得到的最新结果

对以上的部分内容做一个流程般的方法总结。

以下内容以中科大、清华、武大、白百何为例（增加白百何是为了说明这项探究源于高校微博，但是不限于高校）。

首先，情感得分，中科大：0.37；清华：0.26；武大：0.41；白百何：0.36；

可以看出来，情感出问题的是清华和白百何。另外，由于文本分析做的不太成熟，，这里中科大得分接近及格线，应该是属于文本中性词太多。

再得到情感分布曲线（由于其他三个类似上面的得分曲线，因此这里只列出白百何）：

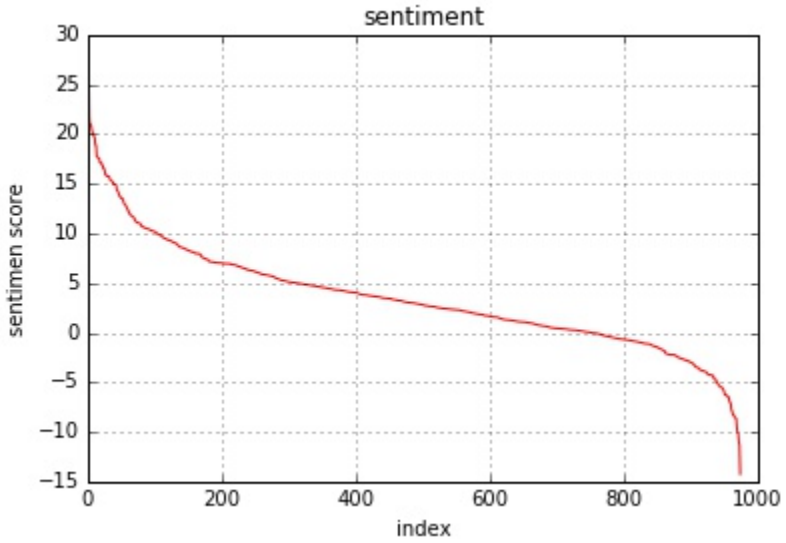

Graph-23 白百何情感得分曲线

正如前面预料的，在低于 0 的部分不是陡峭的（相对而言），说明出了问题。那么出的问题是什么呢？此时就需要提取关键词和主题了。

为方便，将三种方法放在一起。

```
(0, u'0.005*"陈羽" + 0.003*"新闻" + 0.003*"网易" + 0.003*"出轨" + 0.002*"外科" + 0.002*"砸车" +
0.002*"风云" + 0.002*"酒后" + 0.002*"深夜" + 0.002*"卓伟"')
(1, u'0.004*"喜欢" + 0.003*"陈羽" + 0.002*"荣辱与共" + 0.002*"hp" + 0.002*"外科" + 0.002*"砸车" +
0.002*"视频" + 0.002*"离婚" + 0.002*"风云" + 0.002*"出轨"')
(2, u'0.005*"陈羽" + 0.003*"出轨" + 0.003*"喜欢" + 0.003*"离婚" + 0.002*"公司" + 0.002*"视频" +
0.002*"醉酒" + 0.002*"羽凡" + 0.002*"hp" + 0.002*"发文"')
(3, u'0.003*"围观" + 0.003*"外科" + 0.003*"陈羽" + 0.003*"风云" + 0.002*"喜欢" + 0.002*"出轨" +
0.002*"演技" + 0.002*"hp" + 0.002*"视频" + 0.002*"全明星"')
(4, u'0.004*"陈羽" + 0.003*"围观" + 0.002*"娱乐圈" + 0.002*"出轨" + 0.002*"hp" + 0.002*"摊手" +
0.002*"道歉" + 0.002*"离婚" + 0.002*"真的" + 0.002*"羽凡"')

出轨 -> 10
外科 -> 10
全明星 -> 11
过激 -> 12
发文 -> 18
醉酒 -> 18
回应 -> 12
陈羽 -> 78
离婚 -> 9
道歉 -> 7
深夜 -> 9
酒后 -> 11
羽凡 -> 9
卓伟 -> 10
胡歌 -> 8
吐真言 -> 8
砸车 -> 22
言行 -> 12
风云 -> 10
公司 -> 15
hp -> 37
没丫 -> 7
```

Graph-24 白百何关键词

显然出现了“白百何出轨”，“陈羽凡醉酒砸车”，“外科风云”，可以理解的是《外科风云》这部剧对白百何的关键词微博情感有很大的影响，这也是为什么它的情感得分有 0.36，甚至比清华多 0.1.

```
(0, u'0.003*"梦想" + 0.003*"力量" + 0.002*"hp" + 0.002*"东湖" + 0.002*"永远" + 0.002*"嘻嘻" +
0.001*"樱花" + 0.001*"毕业" + 0.001*"珞珈" + 0.001*"声音"')
(1, u'0.002*"hp" + 0.002*"z8AIBJZ" + 0.002*"樱花" + 0.002*"毕业" + 0.001*"允悲" + 0.001*"创业" +
0.001*"教育" + 0.001*"转发" + 0.001*"湖北" + 0.001*"珞珈山"')
(2, u'0.002*"hp" + 0.002*"武大" + 0.002*"新闻" + 0.002*"RUp5wCB" + 0.001*"cry" + 0.001*"大赛" +
0.001*"加油" + 0.001*"good" + 0.001*"樱花" + 0.001*"地点"')
(3, u'0.003*"好看" + 0.002*"hp" + 0.002*"美食" + 0.002*"打卡" + 0.002*"100" + 0.002*"珞珈山" +
0.002*"z8AIBJZ" + 0.002*"武大" + 0.002*"生活" + 0.002*"食堂"')
(4, u'0.003*"建筑" + 0.002*"武大" + 0.002*"cry" + 0.002*"hp" + 0.002*"院长" + 0.002*"图书馆" +
0.001*"喜欢" + 0.001*"珞珈山" + 0.001*"毕业" + 0.001*"100"')

告白 -> 2
同学 -> 2
海燕 -> 2
推广 -> 2
看不见 -> 2
汪苏 -> 2
力量 -> 2
梦想 -> 2
选课 -> 2
樱花 -> 4
hp -> 5
青春 -> 3
合唱团 -> 2
情书 -> 3
白皮书 -> 2
直播 -> 2
永远 -> 2
武大 -> 3
考试 -> 2
泷献唱 -> 2
```

Graph-25 武大关键词

武大的得分相当高，其原因或许是主题偏向“毕业”，“樱花”等等积极的词汇。下面是我们比较关注的两个，中科大和清华：

```
(0, u'0.007*"科学技术" + 0.007*"厉害" + 0.005*"cry" + 0.004*"量子" + 0.004*"good" + 0.004*"计算
机" + 0.004*"科技" + 0.003*"hp" + 0.003*"不错" + 0.003*"光量子"')
(1, u'0.014*"厉害" + 0.004*"科学技术" + 0.004*"机器人" + 0.004*"鼓掌" + 0.003*"量子" +
0.003*"good" + 0.003*"hp" + 0.003*"抱抱" + 0.003*"计算机" + 0.003*"加油"')
(2, u'0.008*"量子" + 0.007*"计算机" + 0.004*"实验" + 0.003*"光量子" + 0.003*"我国" + 0.003*"不明"
+ 0.003*"相干性" + 0.003*"觉厉" + 0.003*"科学技术" + 0.003*"世界"')
(3, u'0.005*"威武" + 0.004*"转发" + 0.004*"计算机" + 0.003*"翘首以盼" + 0.003*"量子" + 0.002*"新
闻" + 0.002*"厉害" + 0.002*"科大" + 0.002*"真的" + 0.002*"祝贺"')
(4, u'0.006*"计算机" + 0.006*"朗读" + 0.004*"量子" + 0.004*"666" + 0.004*"遇见" + 0.003*"新闻" +
0.003*"光量子" + 0.003*"首台" + 0.003*"good" + 0.003*"科学技术"')

首次 -> 7
首台 -> 7
计算机 -> 19
佳佳 -> 8
潘建伟 -> 7
体系 -> 5
哈佛 -> 5
机器人 -> 6
院士 -> 6
超越 -> 5
朗读 -> 6
上海 -> 6
量子 -> 18
诞生 -> 6
研究 -> 5
世界 -> 12
光量子 -> 11
我国 -> 5
干线 -> 5
浙江 -> 7
科学技术 -> 23
科研 -> 7
```

Graph-26 中科大关键词

中科大很显然的是“量子计算机”，“潘建伟”，对比上次的“量子纠缠”。

```
(0, u'0.002*"颜宁" + 0.002*"出走" + 0.002*"普林斯顿" + 0.002*"负气" + 0.002*"美女" + 0.002*"勇敢"
+ 0.002*"转载" + 0.002*"试卷" + 0.001*"hp" + 0.001*"Rh7gfRI"')
(1, u'0.003*"颜宁" + 0.002*"普林斯顿" + 0.002*"故步自封" + 0.002*"自知" + 0.002*"任教" +
0.002*"离开" + 0.002*"环境" + 0.002*"赴美" + 0.002*"新闻" + 0.002*"RaOekx"')
(2, u'0.002*"颜宁" + 0.002*"普林斯顿" + 0.001*"跳槽" + 0.001*"讲席" + 0.001*"美国" + 0.001*"转载"
+ 0.001*"终身" + 0.001*"hp" + 0.001*"研究" + 0.001*"结构"')
(3, u'0.002*"围观" + 0.001*"杨振宁" + 0.001*"颜宁" + 0.001*"一路" + 0.001*"一带" + 0.001*"转载" +
0.001*"回答" + 0.001*"hp" + 0.001*"艺术" + 0.001*"发表"')
(4, u'0.002*"颜宁" + 0.002*"普林斯顿" + 0.001*"制度" + 0.001*"老师" + 0.001*"养老保险" +
0.001*"讲席" + 0.001*"终身" + 0.001*"美国" + 0.001*"世界" + 0.001*"负气"')
```

```
开放 -> 6
态度 -> 6
39 -> 6
充满 -> 6
回应 -> 9
环境 -> 6
美国 -> 7
出走 -> 8
普林斯顿 -> 21
负气 -> 7
陷阱 -> 6
讲席 -> 12
对轻人 -> 6
终身 -> 12
生命 -> 6
颜宁 -> 31
任教 -> 10
制度 -> 10
养老保险 -> 9
跳槽 -> 6
hp -> 24
现行 -> 6
受聘 -> 6
```

Graph-27 清华关键词

实际上，我们最关心的是清华，因为它的得分非常低，综合以上几个关键词，我们可以得出，“颜宁”“负气”“出走”“美国”“普林斯顿”“生物学”，因而基本认定原因是清华讲席教授，分子生物学的专家颜宁负气出走，到美国普林斯顿。

综合以上内容，提取关键词的办法并不完全适合完整认识整个问题，只能是从最大角度看到核心，当然，提取关键词的方法一开始设计的时候是为了研究高校的主题，现在和情感分析结合是超出所能了。

5.5 本章小结

本章用了基于词典的情感分析和基于词典的情感分析，各有优缺点，最后我们用一个具体的案例来说明情感分析的使用方法。在此基础上，我们认为，基于词典的情感分析需要做一些中文语法上的改进，基于机器学习的需要扩大正负语料。而对于情感分析之后的提取关键词，并没有完全达到要求，最需要的是对 LDA 应用于微博的方法做出改进。

第 6 章　传播过程分析

6.1 本章引言

以上内容均是在数据获取的基础上做分析，因而对于博主之间的关系没有做研究，本章将借助工具探究转发关系下的博主关系。

6.2 高校微博的传播特点

这部分的内容是用北京大学微博可视化来实现的。只需要输入 URL 就可以得到下面的图。

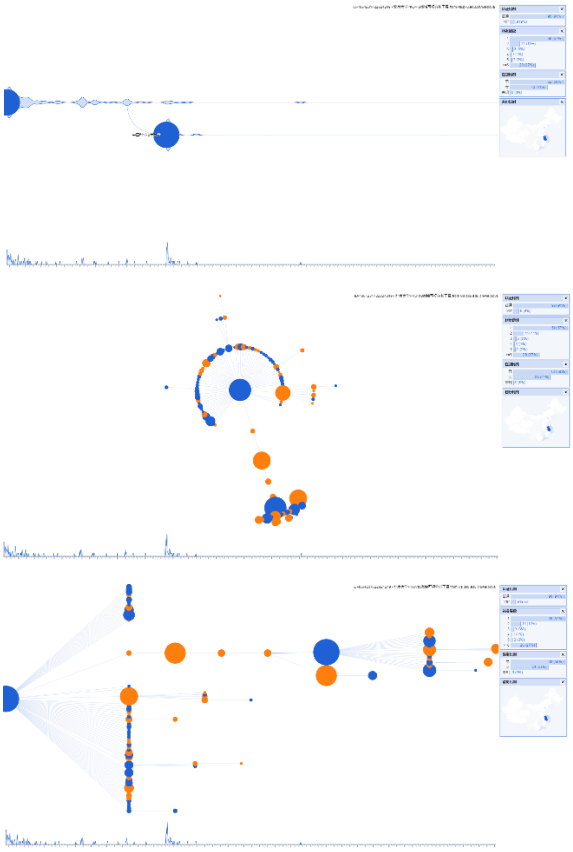

Graph-22 中科大某条热门微博传播图

从上到下依次为曲线视图、环状视图、树状视图，曲线视图表示转发量随时间的变化关系，环状视图中每个圆点代表一个博主，连线代表转发关系，蓝色代表男性，橙色为女性，圆的大小表示该博主粉丝量，圆点组成的圆环代表着转发的层级。树状视图与环状视图类似，而且转发的层级关系更加明确。另外，每个图的右栏都显示了几个数据：转发层级比例、男女比例，分布的地理位置。这里是以中科大为例，下面解释的清北两个大学的传播图不在列出。

三个大学转发关系中均是男性居多，一层转发关系居多，二层很少，其他层次的几乎没有（出了中科大，原因是中科大在该微博经历了几层转发之后，自己转发了该微博），地理位置分布上有较大差异，中科大主要分布在安徽和少部分的东南沿海，而清北从北京开始往下东、南均有分布。另外，转发的热度也是 1-3 天（由于选取的微博是热门微博，否则热度只有一天）。

6.3 明星热门微博的传播特点

以上是我们从高校微博本身得出的结论，可见在传播层面，它们并没有太大的差别，因而没有一个是可以作为范例的，为此，笔者选取了范冰冰的一条热门微博作为参照。

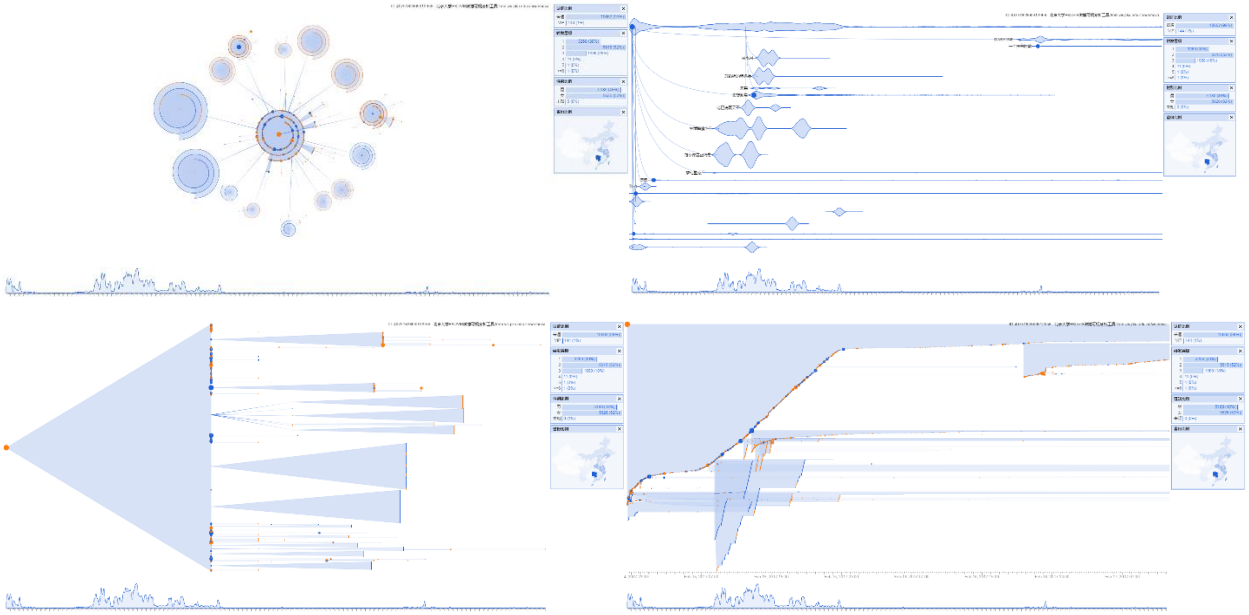

Graph- 范冰冰某条热门微博传播图

可以看出转发层级到了 3 层，有其他大 V 的转发，分布地区非常广泛。对高校的启发是，相互关注的高校可以转发彼此的微博，也就是大 V 的相互转发。另外，还需要注意的是：迎合最新的话题，这也包括了前面的关键词提取和情感监测。

6.4 本章小结

综合明星的热门微博，高校微博的转发量是相当小的，而且转发的层次也远远不足，在不增加宣传的前提下，高校之间的相互转发和互粉可以有效增加影响力。增加传播的范围，则可以通过增加更多地区相关的微博。

第 7 章　总结与展望

本文的结构是建立在数据类型的基础上，首先，我们对 data1 的基本信息数据做了全方位的分析，之后，对 data2 和 data3 的文本做挖掘，最后是用工具对传播做出分析。

整个的研究过程，最重要的应该是有效数据量和对数据的洞察力，以及选取合适的模型。特别对于我们来说，最难的大概是数据的获取，笔者尝试了各种各样的方法，最终还是觉得最好的办法是爬虫，但是限于时间有限，未能成功。在模型方面，LDA 未能找出合适的主题数，以及基于词典的情感分析对中文语法的研究不够深入，导致出现误差的概率较大。后续笔者认为对微博数据爬取的研究是非常有价值的。

参考文献

[1]新浪微博数据爬取研究　陈智，梁娟，谢兵，傅篱（邵阳学院 信息工程系，湖南 邵阳 422000）文章编号：2095-1302（2016）12-0060-04

[2]集搜客网址 http://www.gooseeker.com/
[3]八爪鱼网址 https://www.bazhuayu.com/
[4]火车头网址 http://www.locoy.com/
[5]爬一爬网址 http://www.pa1pa.com/
[6] 北京大学微博可视化 http://vis.pku.edu.cn/weibova/weiboevents/crawler

[7] 魔镜 http://www.moojnn.com/

[8] http://www.cnblogs.com/jerrylead/archive/2011/04/06/2006910.html

[9]http://www.jianshu.com/p/738f6092ef53

[10] http://blog.csdn.net/v_july_v/article/details/41209515

[11] http://blog.csdn.net/a_step_further/article/details/51176959

[12] http://www.jianshu.com/p/4cfcf1610a73

[13] http://f.dataguru.cn/thread-672336-1-1.html

[14] https://site.douban.com/146782/widget/notes/15462869/note/355625387/

[15] http://www.aidnoob.com/ai/python/qinggan1/

[16] http://www.jianshu.com/p/4cfcf1610a73

[17] http://www.jianshu.com/p/8acb99b6671b

[18] http://www.aidnoob.com/ai/python/qinggan2/

[19] 《高校图书馆微博知识推荐影响力研究》马丹琳、程秀峰，北京邮电大学经济管理学院，华中师范大学信息管理学院